

Sintesi della Relazione per la Prova Finale

Candidato: [Davide Livini]

Matricola: [898598]

Relatore: [Andrea Giachero]

Correlatore: [Rodolfo Carobene]

Data della seduta della prova finale: [16-18/09/2026]

Corso di Laurea: Fisica (L-30)

Recapito telefonico: [+39 3270186743]

Titolo: Titolo: Impatto dei canali di rumore sugli algoritmi ibridi quantistico-classici

La Quantum Approximate Optimization Algorithm (QAOA) è un algoritmo variazionale ibrido quantistico-classico progettato per affrontare problemi di ottimizzazione combinatoria su dispositivi quantistici soggetti a rumore. Il lavoro studia l'impatto di diversi canali di rumore sulle prestazioni dell'algoritmo, confrontando tre ottimizzatori classici e utilizzando come caso di studio il problema Max-Cut. Tale problema consiste nel dividere i vertici di un grafo in due sottoinsiemi in modo da massimizzare il numero di archi che collegano vertici appartenenti a sottoinsiemi diversi. La formulazione di Max-Cut in termini di Hamiltoniana di Ising stabilisce una corrispondenza diretta tra il problema di ottimizzazione e la ricerca dello stato a energia minima di un sistema di spin. La stessa struttura compare nello studio di spin glasses, nei quali disordine e frustrazione delle interazioni generano paesaggi energetici complessi, e nei sistemi magnetici geometricamente frustrati, nei quali la geometria del reticolo impedisce di soddisfare simultaneamente tutte le interazioni antiferromagnetiche. Più in generale, la rappresentazione Ising è equivalente a una formulazione QUBO e permette di codificare problemi di ottimizzazione binaria quali partizionamento di grafi, scheduling e allocazione di risorse, vehicle routing e selezione di portafoglio. QAOA può quindi essere applicato a tali problemi attraverso la costruzione di una Hamiltoniana di costo la cui minimizzazione corrisponde alla soluzione dell'istanza considerata.

Per fornire gli strumenti necessari all'analisi, il lavoro introduce alcuni elementi fondamentali di meccanica quantistica e teoria dell'informazione quantistica, tra cui la descrizione dei qubit, gli stati di sovrapposizione, la misura, le trasformazioni unitarie, le porte e i circuiti quantistici. Viene quindi presentata la struttura ibrida di QAOA, basata sull'alternanza di operatori di costo e di mixing e su un ciclo iterativo di ottimizzazione classica. Sono inoltre discussi i principali effetti che limitano l'esecuzione sui dispositivi attuali detti Noisy Intermediate-Scale Quantum (NISQ): l'incertezza dovuta al numero finito di shot, il rumore depolarizzante, gli errori di readout e il rilassamento termico. I tre ottimizzatori classici utilizzati per implementare l'algoritmo QAOA adottano strategie differenti: COBYLA costruisce approssimazioni lineari locali senza usare derivate, SPSA stima una direzione di discesa mediante perturbazioni simultanee dei parametri, mentre L-BFGS-B sfrutta informazioni di gradiente e curvatura. Ciò suggerisce una maggiore adattabilità di SPSA e COBYLA a funzioni obiettivo rumorose e un vantaggio di L-BFGS-B nel caso ideale, caratterizzato da un landscape regolare.

L'implementazione numerica è stata sviluppata in Python utilizzando i pacchetti Qiskit e Qiskit Aer dell'ecosistema IBM Quantum. QAOA è stato applicato a un grafo non pesato costituito da cinque vertici e sei archi, utilizzando un'ansatz di profondità $p = 3$, con sei parametri variazionali. A ciascun vertice è stato associato un qubit. Il circuito QAOA è inizializzato nello stato di sovrapposizione uniforme $|+\rangle^{\otimes 5}$ e costruito mediante l'applicazione alternata dell'operatore di costo e dell'operatore di mixing. Nella convenzione adottata, la Hamiltoniana di costo e la Hamiltoniana di mixing sono definite rispettivamente come

$$H_C = \frac{1}{2} \sum_{(i,j) \in E} (Z_i Z_j - I), \quad H_M = \sum_{i \in V} X_i.$$

Il circuito QAOA applica alternativamente le unitarie $U_C(\gamma_k) = e^{-i\gamma_k H_C}$ e $U_M(\beta_k) = e^{-i\beta_k H_M}$, dove le tre coppie di parametri (γ_k, β_k) , con $k = 1, 2, 3$, sono determinate dal ciclo di ottimizzazione classico. Poiché per ogni stringa binaria x vale $H_C |x\rangle = -C(x) |x\rangle$, minimizzare il valore atteso $\langle H_C \rangle$ equivale a massimizzare il valore atteso del taglio. Per il grafo considerato, il Max-Cut ottimo è pari a 5; gli stati computazionali corrispondenti alle partizioni ottime sono quindi autostati di H_C con autovalore -5 . Nel ciclo ibrido, il valore stimato di $\langle H_C \rangle$ viene passato all'ottimizzatore classico, che aggiorna i parametri del circuito; rumore quantistico ed errore di campionamento agiscono quindi direttamente sulla funzione obiettivo osservata dall'ottimizzatore.

La prima parte degli esperimenti si concentra su un benchmark ideale basato su simulazione state-vector, nel quale il valore atteso della Hamiltoniana di costo viene calcolato senza rumore e senza incertezza da campionamento. Dopo avere caratterizzato il comportamento degli ottimizzatori nel caso ideale, l'analisi si concentra sulle simulazioni rumorose, eseguite con 4096 shot per ogni valutazione della funzione costo. Per ciascun canale di rumore sono stati considerati tre livelli di intensità, scelti come valori sintetici con ordini di grandezza ricavati da dati di calibrazione di hardware reale. Uno studio esplorativo su 20 run indipendenti ha consentito di selezionare le configurazioni più significative, successivamente analizzate su 100 run. È stato infine introdotto un modello a rumore combinato, nel quale rumore depolarizzante, errori di readout e rilassamento termico agiscono simultaneamente.

Nel benchmark ideale L-BFGS-B ha ottenuto la prestazione migliore, con $\langle H_C \rangle = -4.74 \pm 0.15$, rispetto a -4.60 ± 0.32 per COBYLA e -4.39 ± 0.38 per SPSA. Il risultato mostra che l'impiego di informazioni locali di gradiente e curvatura è vantaggioso quando il landscape di ottimizzazione è regolare. L'introduzione del rumore modifica tuttavia tale gerarchia. In presenza di rumore depolarizzante di intensità media, COBYLA ha ottenuto il miglior valore medio, $\langle H_C \rangle = -4.56 \pm 0.29$, mentre SPSA e L-BFGS-B hanno raggiunto valori di -4.38 ± 0.34 e -4.32 ± 0.15 , rispettivamente. Il rumore depolarizzante produce quindi una degradazione contenuta, ma riduce il vantaggio di L-BFGS-B osservato nel caso ideale. Gli errori di readout e il rilassamento termico hanno invece un effetto più marcato. Nel regime low del readout, SPSA raggiunge $\langle H_C \rangle = -4.06 \pm 0.21$, seguito da COBYLA con -3.92 ± 0.17 , mentre L-BFGS-B degrada a -2.47 ± 0.61 . Nel regime low di rilassamento termico, SPSA e COBYLA raggiungono rispettivamente -4.12 ± 0.21 e -3.96 ± 0.15 , mentre L-BFGS-B ottiene -2.47 ± 0.64 . La maggiore dispersione dei risultati di L-BFGS-B evidenzia la sua sensibilità alle fluttuazioni della funzione costo. Il modello a rumore combinato conferma tale comportamento. SPSA fornisce il miglior valore medio, $\langle H_C \rangle = -3.86 \pm 0.15$, corrispondente a un valore atteso del taglio pari a 3.86 su un massimo teorico di 5. COBYLA ottiene un risultato prossimo, $\langle H_C \rangle = -3.75 \pm 0.12$, ma con la minore variabilità, il tempo medio di esecuzione più basso, pari a 0.14 minuti per run, e una probabilità media di campionare una soluzione ottima del 23.6%. L-BFGS-B raggiunge invece -2.59 ± 0.49 , con una probabilità di campionare una soluzione ottima pari all'8.8%.

Nel complesso, L-BFGS-B risulta il più efficace nel caso ideale, ma le sue prestazioni degradano sensibilmente quando le stime della funzione costo sono perturbate da shot noise e canali di rumore quantistico. SPSA massimizza in media la qualità della soluzione nei modelli rumorosi, mentre COBYLA offre il compromesso più favorevole tra qualità della soluzione, stabilità tra run indipendenti e costo computazionale.

La caratterizzazione delle sorgenti di errore costituisce un passaggio necessario per sviluppare strategie in grado di mitigarne o correggerne gli effetti e per avanzare dai dispositivi NISQ verso architetture fault-tolerant. Possibili sviluppi futuri includono l'esecuzione delle stesse configurazioni QAOA su hardware quantistico reale e l'implementazione di tecniche di error mitigation e quantum error correction, con l'obiettivo di migliorare l'affidabilità della funzione costo stimata e la correttezza delle soluzioni finali.

Title: Impact of noise channels on hybrid quantum-classical algorithms

The Quantum Approximate Optimization Algorithm (QAOA) is a hybrid quantum-classical variational algorithm designed to address combinatorial optimization problems on quantum devices affected by noise. This work studies the impact of different noise channels on the performance of the algorithm by comparing three classical optimizers and using the Max-Cut problem as a case study. This problem consists of dividing the vertices of a graph into two subsets in order to maximize the number of edges connecting vertices belonging to different subsets.

The formulation of Max-Cut in terms of an Ising Hamiltonian establishes a direct correspondence between the optimization problem and the search for the lowest-energy state of a spin system. The same structure appears in the study of spin glasses, where disorder and frustration in the interactions generate complex energy landscapes, and in geometrically frustrated magnetic systems, where the geometry of the lattice prevents all antiferromagnetic interactions from being simultaneously satisfied. More generally, the Ising representation is equivalent to a QUBO formulation and makes it possible to encode binary optimization problems such as graph partitioning, scheduling and resource allocation, vehicle routing, and portfolio selection. QAOA can therefore be applied to these problems by constructing a cost Hamiltonian whose minimization corresponds to the solution of the considered instance.

To provide the theoretical tools required for the analysis, the work introduces fundamental concepts of quantum mechanics and quantum information theory, including the description of qubits, superposition states, measurement, unitary transformations, quantum gates, and quantum circuits. The hybrid structure of QAOA is then presented; it is based on the alternating application of cost and mixer operators and on an iterative classical-optimization loop. The main effects limiting execution on current quantum devices, referred to as Noisy Intermediate-Scale Quantum (NISQ) devices, are also discussed: uncertainty due to a finite number of shots, depolarizing noise, readout errors, and thermal relaxation. The three classical optimizers used to implement QAOA adopt different strategies: COBYLA builds local linear approximations without using derivatives, SPSA estimates a descent direction through simultaneous parameter perturbations, whereas L-BFGS-B exploits gradient and curvature information. This suggests that SPSA and COBYLA may be more adaptable to noisy objective functions, whereas L-BFGS-B may have an advantage in the ideal case, characterized by a regular optimization landscape.

The numerical implementation was developed in Python using the Qiskit and Qiskit Aer packages from the IBM Quantum ecosystem. QAOA was applied to an unweighted graph consisting of five vertices and six edges, using an ansatz of depth $p = 3$ with six variational parameters. Each vertex was associated with one qubit. The QAOA circuit is initialized in the uniform superposition state $|+\rangle^{\otimes 5}$ and is constructed by alternating the cost and mixer operators. Under the convention adopted in this work, the cost Hamiltonian and the mixer Hamiltonian are defined, respectively, as

$$H_C = \frac{1}{2} \sum_{(i,j) \in E} (Z_i Z_j - I), \quad H_M = \sum_{i \in V} X_i.$$

The QAOA circuit alternately applies the unitaries $U_C(\gamma_k) = e^{-i\gamma_k H_C}$ and $U_M(\beta_k) = e^{-i\beta_k H_M}$, where the three parameter pairs (γ_k, β_k) , with $k = 1, 2, 3$, are determined by the classical optimization loop. Since each binary string x satisfies $H_C |x\rangle = -C(x) |x\rangle$, minimizing the expectation value $\langle H_C \rangle$ is equivalent to maximizing the expected cut value. For the graph considered, the optimal Max-Cut value is 5; the computational-basis states corresponding to optimal partitions are therefore eigenstates of H_C with eigenvalue -5 . Within the hybrid loop, the estimated value of $\langle H_C \rangle$ is passed to the classical optimizer, which updates the circuit parameters. Quantum noise and sampling error therefore act directly on the objective function observed by

the optimizer.

The first part of the experiments focuses on an ideal benchmark based on statevector simulation, in which the expectation value of the cost Hamiltonian is calculated without noise and without sampling uncertainty. After characterizing optimizer behavior in the ideal setting, the analysis focuses on noisy simulations, performed with 4096 shots for each cost-function evaluation. For each noise channel, three noise-strength levels were considered, selected as synthetic values with orders of magnitude derived from calibration data of real hardware. An exploratory study based on 20 independent runs made it possible to identify the most significant configurations, which were subsequently analyzed over 100 independent runs. Finally, a combined-noise model was introduced, in which depolarizing noise, readout errors, and thermal relaxation act simultaneously.

In the ideal benchmark, L-BFGS-B achieved the best performance, with $\langle H_C \rangle = -4.74 \pm 0.15$, compared with -4.60 ± 0.32 for COBYLA and -4.39 ± 0.38 for SPSA. This result shows that the use of local gradient and curvature information is advantageous when the optimization landscape is regular. The introduction of noise, however, changes this hierarchy. Under medium-strength depolarizing noise, COBYLA achieved the best mean value, $\langle H_C \rangle = -4.56 \pm 0.29$, whereas SPSA and L-BFGS-B obtained -4.38 ± 0.34 and -4.32 ± 0.15 , respectively. Depolarizing noise therefore produces a limited degradation, but reduces the advantage of L-BFGS-B observed in the ideal case. Readout errors and thermal relaxation instead have a more pronounced effect. Under the low-readout-error regime, SPSA reaches $\langle H_C \rangle = -4.06 \pm 0.21$, followed by COBYLA with -3.92 ± 0.17 , whereas L-BFGS-B degrades to -2.47 ± 0.61 . Under the low thermal-relaxation regime, SPSA and COBYLA reach -4.12 ± 0.21 and -3.96 ± 0.15 , respectively, whereas L-BFGS-B obtains -2.47 ± 0.64 . The larger spread of L-BFGS-B results highlights its sensitivity to fluctuations in the cost function. The combined-noise model confirms this behavior. SPSA provides the best mean value, $\langle H_C \rangle = -3.86 \pm 0.15$, corresponding to an expected cut value of 3.86 out of a theoretical maximum of 5. COBYLA achieves a close result, $\langle H_C \rangle = -3.75 \pm 0.12$, but with the lowest variability, the shortest mean runtime of 0.14 minutes per run, and a mean probability of sampling an optimal solution of 23.6%. L-BFGS-B instead reaches -2.59 ± 0.49 , with a probability of sampling an optimal solution equal to 8.8%.

Overall, L-BFGS-B is the most effective method in the ideal case, but its performance degrades substantially when estimates of the cost function are affected by shot noise and quantum noise channels. SPSA maximizes the mean solution quality in noisy models, whereas COBYLA provides the most favorable trade-off among solution quality, stability across independent runs, and computational cost.

Characterizing error sources is a necessary step toward developing strategies to mitigate or correct their effects and to advance from NISQ devices toward fault-tolerant architectures. Possible future developments include executing the same QAOA configurations on real quantum hardware and implementing error mitigation and quantum error correction techniques, with the aim of improving the reliability of the estimated cost function and the correctness of the final solutions.